



دانشگاه صنعتی شریف
دانشکده علوم ریاضی

گزارش پروژه کارشناسی
علوم کامپیوتر

بهبود بازشناسی خودکار گفتار برای گفتار کودکان در زبان فارسی

نگارش

امین هاشمی

استاد راهنما

دکتر علیرضا زارعی

خرداد ۱۴۰۵

چکیده

بازشناسی خودکار گفتار (ASR) برای خردسالان به دلیل ویژگی‌های خاص آناتومیکی مثل کوتاه بودن مجرای صوتی و بالا بودن فرکانس پایه و نیز نارسایی‌های شناختی، با چالش عدم تطابق دامنه مواجه است. این چالش در زبان‌های کم‌منبع مانند فارسی به دلیل کمبود شدید پایگاه داده گفتاری استاندارد کودکان دوچندان می‌شود. پژوهش حاضر با هدف بهبود کیفیت بازشناسی گفتار کودکان فارسی‌زبان، به پیاده‌سازی و ارزیابی یک خط لوله ترکیبی پس‌پردازش متنی و ارزیابی روش تنظیم دقیق کارا (PEFT/LoRA) می‌پردازد. در بخش ارزیابی مدل‌های پایه، مدل‌های خام Vosk و Whisper Base به دلیل توهّم آکوستیکی و ابهام آوایی با نرخ خطای کلمه (WER) بسیار بالایی مواجه شدند. برای بهبود نتایج، یک خط لوله اصلاح متنی چندمرحله‌ای (تطابق قطعی واژگان، تطابق فازی مبتنی بر فاصله لون‌اشتاین و روان‌سازی متنی با مدل زبانی بزرگ) توسعه یافت که عملکرد مدل پایه را بهبود بخشید. همچنین، تغذیه مستقیم سیگنال صوتی به مدل چندوجهی بهترین عملکرد کلی پژوهش و کمترین میزان نرخ خطا را به ثبت رساند. ارزیابی فرآیند تنظیم دقیق لورا روی نمونه‌های واقعی گفتار کودکان و جملات صوتی شبیه‌سازی شده نشان داد که این روش موجب ارتقای کارایی مدل کوچک Whisper Base می‌شود؛ اما در مدل بزرگ Whisper Large-v3 به دلیل ظرفیت بالای پارامترها و محدودیت شدید داده‌های آموزشی، به بیش‌برازش و فراموشی فاجعه‌بار منجر شده و عملکرد آن را تخریب می‌کند. یافته‌های این پژوهش نشان می‌دهد در شرایط کم‌منبع، استفاده از خط لوله‌های پس‌پردازش زبانی یا مدل‌های چندوجهی مستقیم، رویکرد عملیاتی بسیار موفق‌تری نسبت به تنظیم دقیق آکوستیک است.

واژه‌های کلیدی: بازشناسی خودکار گفتار، گفتار کودکان، زبان فارسی، پس‌پردازش متنی، مدل‌های زبانی بزرگ، تنظیم دقیق کارا، لورا.

فهرست مطالب

۱	کلیات پژوهش	۱
۱-۱	مقدمه و پیش‌زمینه پژوهش	۱
۲-۱	تعریف مسئله	۲
۳-۱	ادبیات پژوهشی و بررسی سوابق علمی	۲
۱-۳-۱	ارزیابی گفتار کودکان با رویکرد دستکاری فرکانسی	۲
۲-۳-۱	تصحیح خطای زایشی مبتنی بر بازیابی افزوده (GEC-RAG)	۳
۳-۳-۱	مدل‌سازی نویز در سطح خطا با کمک LLM	۳
۴-۳-۱	تصحیح املای فارسی با تلفیق تحلیل آوایی (PERCORE)	۳
۴-۱	اهداف پژوهش	۴
۲	روش‌شناسی و معماری سیستم پیشنهادی	۵
۱-۲	مقدمه و نمای کلی خط لوله پردازشی	۵
۲-۲	پیش‌پردازش آکوستیک و تنظیمات مدل پایه	۶
۱-۲-۲	انتخاب مدل استنتاجگر (ASR Model Selection)	۶
۲-۲-۲	مهندسی پرامپت در مدل آکوستیک (Prompt Engineering)	۶
۳-۲	پس‌پردازش کلاسیک (Classic Postprocessing)	۷
۱-۳-۲	تطابق دقیق (Exact Lexicon Matching)	۷
۲-۳-۲	تطابق فازی (Fuzzy Matching)	۷

۴-۲	پس‌پردازش مبتنی بر مدل بزرگ زبانی (LLM)	۸
۴-۲-۱	تفاوت‌های ساختاری Web App و API در مدل‌های زبانی	۸
۵-۲	معماری جایگزین: پردازش مستقیم صدا توسط LLM	۸
۶-۲	الگوریتم کلی	۹
۳	یافته‌ها و نتایج	۱۰
۳-۱	محیط آزمایش و مشخصات مجموعه داده	۱۰
۳-۱-۱	پیکره‌های گفتاری ارزیابی و آموزش	۱۰
۳-۱-۲	پیش‌پردازش سیگنال و یکسان‌سازی آکوستیکی	۱۱
۳-۲	ارزیابی عملکرد مدل‌های پایه آکوستیک	۱۱
۳-۲-۱	تحلیل و ریشه‌یابی عملکرد مدل‌ها	۱۲
۳-۳	ارزیابی خوراک صوتی مستقیم چندوجهی	۱۳
۳-۳-۱	تحلیل رفتار و علل شکست مدل محلی Qwen2-Audio	۱۳
۳-۳-۲	تحلیل کارایی متمایز مدل‌های چندوجهی گوگل (Gemini)	۱۴
۳-۳-۳	پیکره‌های گفتاری و پیکربندی تنظیم دقیق کارا (PEFT/LoRA)	۱۵
۴-۳	بحث و مقایسه جامع روش‌ها	۱۷
۵-۳	نتیجه‌گیری	۱۸
۶-۳	چشم‌اندازهای توسعه	۱۹

۲۱	مراجع
----	-------

فهرست جداول

- ۱-۳ مقایسه عملکرد مدل‌های آکوستیک پایه (خام) بر روی گفتار کودکان فارسی‌زبان . . . ۱۲
- ۲-۳ مقایسه عملکرد سامانه‌های خوراک صوتی مستقیم چندوجهی بر روی گفتار کودکان . . ۱۳

فهرست نمودارها

- ۱-۳ مقایسه جامع نرخ خطای کلمه (WER) و نویسه (CER) مدل‌های مختلف بر روی
گفتار کودکان ۱۵
- ۲-۳ مقایسه تاثیر تنظیم دقیق کارا (LoRA) بر نرخ خطای کلمه (WER) در مجموعه داده
آزمون مستقل ۱۶
- ۳-۳ نمودار پراکندگی نرخ خطای کلمه (WER) در برابر نرخ خطای نویسه (CER) ۱۷

فصل ۱

کلیات پژوهش

۱-۱ مقدمه و پیش زمینه پژوهش

پردازش زبان طبیعی و بازشناسی خودکار گفتار (ASR)، در سال‌های اخیر با تغییرات بنیادین و پیشرفت‌های شگرفی مواجه شده است. گذار از مدل‌های آماری کلاسیک مانند مدل‌های مخفی مارکوف (HMM) و مدل‌های مخلوط گوسی (GMM) به معماری‌های مبتنی بر یادگیری عمیق (Deep Learning)، شبکه‌های عصبی بازگشتی (RNN) و در نهایت معماری‌های مبتنی بر توجه (Attention) و ترنسفورمرها (Transformers)، توانمندی ماشین‌ها را در درک گفتار انسان به سطحی بی‌سابقه ارتقا داده است [۱]. با وجود این دستاوردهای عظیم در زبان‌های پرمبوع (High-Resource Languages) مانند انگلیسی، توسعه سامانه‌های بازشناسی گفتار برای زبان‌هایی که دارای منابع دادگان محدودتری هستند (Low-Resource Languages) همچنان به عنوان یکی از چالش‌های بنیادین در حوزه پردازش زبان طبیعی شناخته می‌شود. زبان فارسی، با وجود گستردگی گویشوران، به دلیل پیچیدگی‌های بی‌شمار آواشناختی، تنوع ساختارهای صرفی و نحوی، و همچنین کمبود پیکره‌های گفتاری استاندارد، در زمره زبان‌هایی قرار می‌گیرد که نیازمند رویکردهای ویژه‌ای است [۲].

پردازش «گفتار کودکان» یکی از زمینه‌های تحقیقاتی پیچیده و چالشی در حوزه پردازش گفتار طبیعی است [۳]. مدل‌های پایه‌ای پیش‌فرض که امروزه در دسترس قرار دارند (مانند Whisper یا Wav2Vec2)، تقریباً به صورت انحصاری بر روی صدها هزار ساعت از گفتار بزرگسالان آموزش دیده‌اند [۱]. گفتار کودکان به دلایل فیزیکی [۴] و شناختی، انحراف شدیدی از توزیع داده‌های آموزشی این مدل‌ها دارد. از منظر آناتومی، طول مجرای صوتی کودکان کوتاه‌تر است که منجر به افزایش فرکانس پایه (Fundamental Frequency - F0) و جابجایی فرکانس‌های فرمانت (Formant Frequencies) می‌شود [۵].

بنابراین، راهبرد بهینه و مقیاس‌پذیر برای غلبه بر این محدودیت‌ها (بدون نیاز به بازآموزی پرهزینه مدل‌های بزرگ)، تغییر رویکرد به سمت ایجاد یک خط لوله ترکیبی (Hybrid Pipeline) چندمرحله‌ای است که شامل پیش‌پردازش سیگنال صوتی، استنتاج توسط مدل پایه، و پس‌پردازش متنی و زبانی (Contextual Post-processing) با بهره‌گیری از مدل‌های زبانی بزرگ (LLM) می‌باشد [۶].

۲-۱ تعریف مسئله

مسئله اصلی این پژوهش، ضعف ساختاری و عملکردی مدل‌های بازشناسی خودکار گفتار در تشخیص و تبدیل دقیق گفتار کودکان به متن در زبان فارسی است. زمانی که یک سیستم با داده‌هایی مواجه می‌شود که با داده‌های زمان آموزش تفاوت فاحشی دارند، پدیده‌ای به نام عدم تطابق حوزه (Domain Mismatch) رخ می‌دهد.

برای درک بهتر، بررسی پایگاه‌های داده گفتاری نشان می‌دهد که منابع کلیدی موجود، نظیر پیکره PSRB [۲]، Common Voice، و پیکره مهر [۷]، اکثراً مبتنی بر صدای بزرگسالان جمع‌آوری شده‌اند. مشاهدات تجربی اولیه در این پروژه با استفاده از مدل Whisper بر روی گفتار کودکان نشان‌دهنده نرخ خطای کلمه (WER) در محدوده ۷۸ الی ۸۳ درصد بود که عملاً استفاده از این سیستم را غیرممکن می‌سازد.

علاوه بر چالش آکوستیکی، زبان فارسی چالش‌های متنی پیچیده‌ای را نیز تحمیل می‌کند [۲]:

- چسبیده یا جدا بودن کلمات (مثل «می‌نویسم» در برابر «مینویسم») که خطای سیستم را به صورت کاذب بالا می‌برد.
- تمایل گویندگان خردسال به استفاده از فرم محاوره‌ای (مثل «می‌خوام» به جای «می‌خواهم»).
- پدیده هکسره: اشتباه در مکتوب کردن مصوت کوتاه کسره به صورت حرف «ه».

۳-۱ ادبیات پژوهشی و بررسی سوابق علمی

۱-۳-۱ ارزیابی گفتار کودکان با رویکرد دستکاری فرکانسی

۱. عباسکوهی و همکاران [۳] استدلال می‌کنند که استفاده مستقیم از سیستم‌های متعارف ASR برای گفتار کودکان کارآمد نیست، زیرا این مدل‌ها روی داده‌هایی با دامنه و فرکانس متفاوت یا به بیانی بزرگسالان

آموزش دیده‌اند. برای حل این مشکل، آن‌ها یک تابع هدف جدید به نام گام فرکانس تصادفی (RFP) را به فرآیند آموزش مدل Wav2Vec 2.0 افزودند. این روش نوعی دستکاری فرکانسی است که ساختار صوتی کودکان را شبیه‌سازی می‌کند. در چارچوب پروژه‌ی من، این مفهوم پایه‌گذار لایه «پیش‌پردازش آکوستیک» است تا بدون دستکاری معماری مدل، سیگنال خام را نرمال‌سازی کنیم.

۱-۳-۲ تصحیح خطای زایشی مبتنی بر بازیابی افزوده (GEC-RAG)

۱. رباطیان و همکاران [۶] راهکار مقیاس‌پذیری را برای ارتقای خروجی ASR به عنوان یک «جعبه‌سیاه» معرفی می‌کند. سیستم، الگوهای خطای پیشین را از یک پایگاه دانش (شامل فرضیه‌های مدل و متن صحیح) استخراج کرده و آن‌ها را در کنار متن خام فعلی به یک مدل زبانی بزرگ (LLM) می‌فرستد. مدل زایشی با استفاده از یادگیری درون‌بافتی (In-Context Learning)، خطاهای آکوستیک را هدفمند اصلاح می‌کند. این روش اهمیت لایه پس‌پردازش پیشنهادی در پروژه‌ی من را برجسته می‌کند؛ جایی که با مهندسی پرامپت آگاه از بافت، می‌توانیم خطاهای مختص صدای کودکان را برطرف نماییم.

۱-۳-۳ مدل‌سازی نویز در سطح خطا با کمک LLM

افت عملکرد در محیط‌های پرنویز از چالش‌های اساسی ASR فارسی است. رحمانی و همکاران [۸] با استخراج پنج فرضیه برتر (5-best) از مدل Whisper، میزان تناقض بین آن‌ها را محاسبه کردند. این تفاوت‌ها در قالب بردارهای «تعبیه نویز در سطح خطا» (ELN) به عنوان یک سیگنال ورودی به LLM داده می‌شوند و به مدل اجازه می‌دهند عملیات «نویزگیری متنی» را با آگاهی از کیفیت صدای ورودی انجام دهد. در خط لوله پروژه من، تحلیل خروجی‌های جایگزین برای یافتن کلمات صحیح از طریق تطابق فازی، مستقیماً از این بینش الهام گرفته شده است.

۱-۳-۴ تصحیح املاي فارسی با تلفیق تحلیل آوایی (PERCORE)

چارچوب PERCORE [۹]، یادگیری عمیق را با تحلیل‌های واج‌شناختی ترکیب می‌کند تا خطاهای املايی زبان فارسی را (به‌ویژه خطاهای کلمات واقعی با شباهت آوایی نظیر «خوار» و «خار») اصلاح کند. با وارد کردن ابعاد واج‌شناختی کلمات به فضای برداری مدل، دقت تصحیح به شدت افزایش می‌یابد.

۴-۱ اهداف پژوهش

هدف ما، پیاده‌سازی و ارزیابی یک خط لوله نرم‌افزاری ترکیبی برای بهبود کارایی ASR در برابر گفتار کودکان فارسی‌زبان است، بدون آنکه نیاز به منابع سخت‌افزاری عظیم باشد. روند کار شامل فاز ارزیابی کمی خام (Baseline)، اعمال الگوریتم‌های پیش‌پردازش آکوستیک، و در نهایت توسعه لایه پس‌پردازش کلاسیک و مبتنی بر LLM جهت رفع اشکالات متنی و دستور زبانی است.

فصل ۲

روش‌شناسی و معماری سیستم پیشنهادی

۱-۲ مقدمه و نمای کلی خط لوله پردازشی

ضعف‌های بنیادین مدل‌های استاندارد تبدیل گفتار به متن در پردازش گویش‌های خاص، گفتار کودکان و اصطلاحات تخصصی، نیازمند اتخاذ رویکردهای جامع پس‌پردازشی است [۱۰]. مدل‌های استاندارد معمولاً در مواجهه با ابهامات آوایی، ساختارهای غیررسمی، و رعایت قواعد نگارشی زبان فارسی نظیر فاصله‌گذارهای صفر دچارافت دقت چشمگیری می‌شوند [۲، ۸].

برای غلبه بر این چالش‌ها، سیستم پیشنهادی در این پژوهش به صورت یک معماری چندمرحله‌ای (Pipeline) طراحی شده که در قالب پردازش‌های ناهمگام (Asynchronous) در پس‌زمینه عمل می‌کند. این خط لوله به طور کلی از پنج فاز کلیدی تشکیل شده است:

۱. استنتاج اولیه (Speech-to-Text): دریافت سیگنال صوتی و تولید متن خام با استفاده از مدل Whisper.

۲. تصحیح واژگانی دقیق (Lexicon Exact Matching): اعمال قواعد تطابق دقیق برای اصلاح خطاهای متداول رونویسی با استفاده از یک پایگاه داده‌ی مرجع.

۳. تطابق فازی (Fuzzy Matching): کشف و اصلاح خطاهای املایی نزدیک به کلمات هدف با استفاده از معیار فاصله لوناشتاین [۱۱].

۴. پاک‌سازی متنی مبتنی بر مدل زبانی (LLM-Based Cleanup): بهره‌گیری از مدل‌های LLM (مانند Gemini 3.5 Flash) جهت رفع خطاهای گرامری، اصلاح مرز کلمات و حذف

۲-۲ پیش‌پردازش آکوستیک و تنظیمات مدل پایه

پیش‌ازارسال سیگنال صوتی به مدل استنتاج، کیفیت داده‌ها به عنوان یک عامل تعیین‌کننده بررسی می‌شود. با اینکه بهبود کیفیت صدای خام از طریق حذف نویز پس‌زمینه، یکسان‌سازی بلندی صدا، و تنظیم فرکانس روی باند ۳۰۰ تا ۳۴۰۰ هرتز (به کمک ابزارهایی نظیر RNNoise و ffmpeg) قابل انجام است، ارزیابی‌های اولیه نشان می‌دهد که تأثیر این اقدامات غالباً محدود بوده و نیازمند صرف زمان پردازشی مازاد است. لذا اولویت اصلی بر بهینه‌سازی فرمت صوت (تبدیل به مونو و نرخ نمونه‌برداری ۱۶ کیلوهرتز) قرار داده شد.

۱-۲-۲ انتخاب مدل استنتاجگر (ASR Model Selection)

بررسی دقیق نسخه‌های مختلف مدل Whisper برای پردازش زبان فارسی نشان‌دهنده یک بده‌بستان (Trade-off) میان دقت و سرعت است [۱]:

- **مدل Whisper Base**: با وجود سرعت بسیار بالا و سبک بودن، دارای دقت پایینی است و صرفاً برای دستگاه‌های با منابع سخت‌افزاری بسیار محدود توصیه می‌شود.

- **مدل Whisper Large V3**: این مدل که برای زبان فارسی نیز Fine-Tuned شده است، بالاترین سطح دقت را در محیط‌های پرنویز و فایل‌های چندگوشه ارائه می‌دهد.

با توجه به محدودیت‌های پردازشی، در این پروژه از API رسمی OpenAI و همچنین از مدل‌های ابری با درجه حرارت تنظیم‌شده روی صفر ($temperature = 0$) استفاده شد تا رفتار مدل کاملاً قطعی و پایدار باقی بماند [۱۳].

۲-۲-۲ مهندسی پرامپت در مدل آکوستیک (Prompt Engineering)

تزریق پرامپت‌های راهنما به مدل ASR در حین استنتاج یکی از راهکارهای موثر است. بررسی‌ها نشان می‌دهد که جایگزین کردن «پرامپت‌های مبتنی بر واژگان» (فقط شامل کلمات کلیدی) با «پرامپت‌های مبتنی بر مثال» (Example-Based Prompts) که شامل نمونه‌های واقعی و ساختاریافته از خروجی‌های مطلوب هستند، می‌تواند درک بافتی مدل پایه را حتی پیش از ورود به لایه پس‌پردازش به شدت افزایش دهد.

Vocabulary-based: 'مدرسه، مامان، بابا، بازی، خوراکی، خاله، اسباب بازی، رفتم...'.
 Example-Based: 'سلام خوبی؟ من امروز رفتم مدرسه با دوستانم بازی کردم. مامانم برام خوراکی خریده بود. خاله زهرا هم اومده بود خونمون. اسباب بازی رو هم بردم.'

۳-۲ پس پردازش کلاسیک (Classic Postprocessing)

به دلیل خطاهای مکرر سیستم‌های ASR در شناسایی صحیح کلمات مشابه (هم‌صداها و اشتباهات تلفظی)، متکی بودن به روش‌های مبتنی بر واژه‌نامه محلی (Lexicon) به عنوان راهکاری قطعی و بسیار سریع، مورد استفاده قرار گرفت. این رویکرد به دو شاخه تقسیم می‌شود:

۱-۳-۲ تطابق دقیق (Exact Lexicon Matching)

در این گام، ده‌ها قاعده تصحیح صریح (Correction Rules) که از خطاهای رایج قبلی مدل و لحن خاص کودکان استخراج شده‌اند، روی متن خام اعمال می‌شود. این رویکرد، خطاهای آوانگاری مرسوم و تلفظ‌های کودکانی کلمات (مانند تبدیل «مدلسه» یا «ملاسه» به «مدرسه» و «لغتم» به «رفتم») را به صورت قطعی تصحیح می‌کند.

۲-۳-۲ تطابق فازی (Fuzzy Matching)

ارزیابی استراتژی‌های ارتقای کیفیت نشان می‌دهد که الگوریتم تطابق فازی، بالاترین میزان اثربخشی را در کاهش خطاهای سیستم در میان تمام روش‌ها داراست. این روش از معیار «فاصله لوشتاین»^۱ [۱۱] با آستانه مجاز ۲ ≤ استفاده می‌کند تا اشتباهات آوایی و املائی نزدیک به واژگان هدف را شکار کند. به عنوان نمونه، سیستم قادر است کلمه نامتعارف «بزولگ» (ناشی از تلفظ کودکان) را به «بزرگ»، و یا واژه اشتباه «خاهش» را به «خواهش» اصلاح نماید.

^۱ Levenshtein Distance

۴-۲ پس پردازش مبتنی بر مدل بزرگ زبانی (LLM)

حتی با اعمال دقیق‌ترین فیلترهای کلاسیک، چالش‌های پیچیده‌ای نظیر پدیده هکسره، جدانویسی‌های نابجا، و شکسته‌نویسی‌های گفتار محاوره‌ای، نیازمند درک عمیق از دستور زبان و معناشناسی هستند [۱۲، ۲]. برای حل این مسئله، خروجی مرحله کلاسیک به یک مدل زبانی بزرگ نظیر Gemini 3.5 ارسال می‌گردد.

۱-۴-۲ تفاوت‌های ساختاری Web App و API در مدل‌های زبانی

طبق مستندات شرکت OpenAI [۱۳]، در محیط وب علاوه بر پرامپت، المان‌های دیگری مثل کوکی‌ها و شرایط رابط کاربری نیز بر رفتار مدل تاثیر می‌گذارند در حالیکه هنگام توسعه با API، پرامپت مسئولیت تمامی این موارد را بر عهده دارد.

۵-۲ معماری جایگزین: پردازش مستقیم صدا توسط LLM

در این پژوهش رویکرد ارسال مستقیم سیگنال صوتی به مدل‌های زبانی چندوجهی (بدون واسطه ASR) نیز مورد ارزیابی قرار گرفت. با توجه به عدم پشتیبانی مدل‌های رایگان OpenAI از این قابلیت، از خانواده مدل‌های گوگل استفاده شد [۱۴، ۱۳]. مدل Gemini 3.5 Flash با پشتیبانی از ورودی مستقیم صوت و محدودیت ترافیکی معادل ۲۵۰ هزار توکن در دقیقه (TPM) و ۵ درخواست در دقیقه (RPM) مورد تست قرار گرفت [۱۴]. مشاهدات اولیه حاکی از آن است که حذف لایه واسطه ASR در برخی سناریوها منجر به درک بهتر لحن و تولید متن دقیق‌تر می‌گردد، هرچند که محدودیت‌های شدید API استفاده مقیاس‌پذیر از آن را مختل می‌سازد که برای رفع حدودی آن، از کلیدهای API چرخشی استفاده شد.

۶-۲ الگوریتم کلی

روند اجرای کلی پروژه در خط لوله پیشنهادی را می‌توان به صورت زیر بیان کرد:

Algorithm 1 Multi-Stage Speech Transcription and Correction Pipeline

- 1: **Input:** Audio source (Cached, Local, or Live Microphone)
 - 2: **Output:** Final Corrected Text
 - 3: Clean audio data (format alignment to mono 16kHz)
 - 4: $T_{raw} \leftarrow$ Transcribe using ASR Model with example-based initial prompt
 - 5: $T_{exact} \leftarrow$ Perform exact matching correction rules on T_{raw}
 - 6: $T_{fuzzy} \leftarrow$ Perform fuzzy matching (Levenshtein ≤ 2) on T_{exact}
 - 7: $T_{final} \leftarrow$ LLM-based post-processing on T_{fuzzy} (Grammar, Spacing, Context)
 - 8: T_{final}
-

فصل ۳

یافته‌ها و نتایج

در این فصل، به ارزیابی تجربی و تحلیل کمی و کیفی عملکرد خط لوله پیشنهادی و مقایسه آن با مدل‌های پایه و رویکردهای مختلف چندوجهی و تصحیح خطا می‌پردازیم. ارزیابی‌ها بر مبنای تنظیمات و جزئیات معماری توصیف شده در فصل دوم انجام شده‌اند. ابتدا مشخصات بستر محاسباتی و جزئیات مجموعه داده‌های بکاررفته (شامل داده‌های طبیعی و سنتز شده) تشریح می‌شود. در ادامه، عملکرد مدل‌های پایه آکوستیک، لایه‌های پس پردازش متنی کلاسیک و مولد، و در نهایت خوراک صوتی مستقیم چندوجهی ارزیابی می‌گردد. در بخش پایانی فصل نیز، نتایج حاصل از تنظیم دقیق کارا (PEFT) با معماری لورا (LoRA) بر روی مدل‌های Whisper مورد واکاوی و بحث قرار می‌گیرد.

۳-۱ محیط آزمایش و مشخصات مجموعه داده

تحلیل و ارزیابی سامانه‌های بازشناسی گفتار کودکان در زبان‌های کم‌منبع، مستلزم استقرار یک بستر محاسباتی پایدار و تعریف دقیق پیکره‌های صوتی است تا محدودیت‌های عملیاتی این حوزه به درستی مدل‌سازی شوند.

۳-۱-۱ پیکره‌های گفتاری ارزیابی و آموزش

با توجه به کمبود شدید دادگان گفتاری متوالی متعلق به کودکان فارسی زبان، در این پژوهش از دو منبع داده مجزا اما مکمل استفاده شده است:

۱. بخش کودک مجموعه داده PSRB: به عنوان پیکره اصلی برای ارزیابی عملکرد واقعی سیستم، از

مجموعه داده بنچمارک جامع بازشناسی گفتار فارسی (PSRB) [۲] استفاده گردید. با اعمال فیلتر گروه سنی بر روی این دادگان، نمونه‌های متعلق به گویندگان خردسال استخراج شد که در مجموع شامل ۱۴ نمونه گفتار طبیعی بود. جهت انجام یک ارزیابی پایدار، این نمونه‌ها به سه بخش آموزش (۱۱ نمونه)، اعتبارسنجی (۱ نمونه) و آزمون مستقل (۲ نمونه) تقسیم شدند.

۲. **دادگان گفتار کودکان دانشگاه تهران (DSP-UT):** به دلیل تعداد بسیار کم جملات متوالی طبیعی کودکان، جهت تعمیم‌دهی بهتر مدل در فاز آموزش لورا، از دادگان گفتار کودکان گردآوری شده توسط م. خانزادی و همکاران [۱۵] استفاده گردید. این پیکره حاوی صداهای ضبط‌شده تک‌کلمه‌ای از کودکان پیش‌دبستانی برای واژگانی نظیر «آهو»، «قطار»، «قیچی» و «هواپیما» است. برای ایجاد جملات شبیه‌سازی‌شده، فرآیند چسباندن صوتی (Audio Stitching) طراحی شد. در این فرآیند، برای تولید هر جمله صوتی، تعداد ۶ کلمه به صورت تصادفی انتخاب گردید و فایل‌های صوتی آن‌ها با اعمال وقفه سکوت کوتاه به مدت ۰/۲ ثانیه به یکدیگر متصل شدند. بدین وسیله، تعداد ۱۰۰ جمله صوتی سنتز شده به همراه متن مرجع معادل آن‌ها تولید و به مجموعه آموزش اضافه شد.

۳-۱-۲ پیش‌پردازش سیگنال و یکسان‌سازی آکوستیکی

به منظور انطباق داده‌های صوتی ورودی با نیازمندی‌های ورودی مدل‌های آکوستیک پایه، تمامی فایل‌های صوتی خام پیش از ارسال به مدل یکسان‌سازی شدند. این فرآیند شامل تبدیل سیگنال‌های استریو به تک‌کاناله (Mono) و بازنمونه‌برداری صوتی به فرکانس ۱۶ کیلوهرتز (۱۶ kHz) بود [۱۳]. همچنین عملیات نرمال‌سازی حجم صدا صورت گرفت تا نوسانات شدید دامنه سیگنال صوتی که ناشی از تغییر موقعیت کودکان نسبت به میکروفون است، به حداقل برسد.

۳-۲ ارزیابی عملکرد مدل‌های پایه آکوستیک

پیش از بررسی تأثیر رویکردهای پس‌پردازش متنی و روش‌های تنظیم دقیق، شناسایی دقیق توانمندی‌ها و گلوگاه‌های مدل‌های آکوستیک خام در مواجهه با گفتار کودکان فارسی‌زبان از اهمیت بالایی برخوردار است. در این بخش، عملکرد سه مدل پایه آکوستیک یعنی مدل آفلاین سبک Vosk، مدل ترانسفورمر Whisper Base و مدل بزرگ زیرو-شات^۱ Whisper Large-v3 بر روی نمونه‌های کودک مجموعه داده PSRB ارزیابی و تحلیل می‌گردد.

^۱ Zero-Shot Baseline

نتایج کمی حاصل از ارزیابی این مدل‌های پایه در جدول ۳-۱ خلاصه شده است.
 جدول ۳-۱: مقایسه عملکرد مدل‌های آکوستیک پایه (خام) بر روی گفتار کودکان فارسی زبان

مدل آکوستیک پایه	تعداد پارامترها	نرخ خطای کلمه (WER)	نرخ خطای نویسه (CER)	میانگین فاصله ویرایشی
Vosk (خام)	بسیار سبک	۹۴/۶۹٪	۶۶/۲۸٪	۱۶/۸۵
Whisper Base (خام)	حدود ۷۴ میلیون	۱۰۲/۷۷٪	۵۰/۲۵٪	۱۸/۴۰
Whisper Large-v3 (خام)	حدود ۵/۱ میلیارد	۵۴/۸۹٪	۲۱/۹۱٪	۹/۱۵

۳-۲-۱ تحلیل و ریشه‌یابی عملکرد مدل‌ها

واکاوی داده‌های جدول ۳-۱ نشان‌دهنده چالش‌های عمیق آکوستیکی و زبانی در پردازش صدای کودکان است:

۱. پدیده توهم و تکرار در مدل‌های ترانسفورمر سبک (Whisper Base): ثبت نرخ خطای کلمه فراتر از صد درصد (۱۰۲/۷۷٪) برای مدل Whisper Base، شاهی بر وقوع پدیده «بیش‌تولید»^۲ یا توهم آکوستیکی است. در فرمول محاسبه خطای کلمه:

$$WER = \frac{S + D + I}{N}$$

بخش مخرج کسر (N) معرف کلمات متن مرجع است، در حالی که در صورت کسر، خطاهای جایگزینی (S)، حذف (D) و درج (I) جمع می‌شوند. مدل Whisper Base به دلیل حجم کم پارامترها و حساسیت بالا به فرکانس‌های صوتی بالا از جمله صدای زیر کودکان، دچار گمراهی آکوستیکی شده و اقدام به درج مکرر کلمات هم‌قافیه یا تکرار بیهوده واژه‌ها می‌کند که منجر به پیشی گرفتن شمار خطاهای درج از طول مرجع و در نتیجه ثبت خطای بالای ۱۰۰ درصد می‌شود.

۲. محدودیت ساختاری مدل‌های آفلاین ترکیبی (Vosk): مدل Vosk اگرچه خطای کلمه کمتری نسبت به Whisper Base نشان می‌دهد (۹۴/۶۹٪)، اما خطای نویسه بسیار بالایی دارد (۶۶/۲۸٪). ساختار مدل Vosk مبتنی بر یک مدل زبانی محدود آکوستیکی آفلاین است که کلمات خارج از واژه‌نامه مجاز را بازشناسی نمی‌کند. این مدل برخلاف مدل‌های مولد، بدلیل عدم بهره از معماری RAG دچار توهم یا تکرار عبارات طولانی نمی‌شود، اما به دلیل عدم تطابق آکوستیکی شدید، کلمات ادا شده توسط کودک را با کلمات مشابه صوتی در واژه‌نامه خود جایگزین می‌کند. این موضوع تفاوت شدید حروف نگارش شده با متن اصلی (بالا بودن CER) را توجیه می‌نماید.

^۲ Over-generation

۳. نقش مقیاس مدل در مقاومت آکوستیکی: مدل Whisper Large-v3 به عنوان نسخه پایه بزرگ، بهبود فوق‌العاده‌ای نشان می‌دهد و خطای کلمه را به ۵۴/۸۹٪ و خطای نویسه را به ۲۱/۹۱٪ کاهش می‌دهد. تعداد پارامترهای بالا و آموزش بر روی حجم عظیمی از داده‌های صوتی ضعیف نظارت‌شده^۳ به این مدل اجازه می‌دهد تا بازنمایی‌های آکوستیکی مقاوم‌تری در برابر جابجایی فرکانس‌های صدای کودکان استخراج کند.

۳-۳ ارزیابی خوراک صوتی مستقیم چندوجهی

یک رویکرد نوین در حوزه پردازش گفتار، حذف لایه واسطه بازشناسی گفتار (ASR) و ارسال مستقیم سیگنال صوتی خام به عنوان ورودی به مدل‌های زبانی بزرگ چندوجهی (Multimodal LLMs) است. در این معماری تک‌مرحله‌ای، مدل زبانی به طور همزمان سیگنال صوتی و دستورالعمل متنی (پرامپت) را دریافت کرده و استنتاج آکوستیکی و روان‌سازی متنی را به صورت یکپارچه در یک Forward Pass انجام می‌دهد.

در این بخش، عملکرد مدل محلی متن‌باز Qwen2-Audio-7B با مدل‌های ابری چندوجهی گوگل یعنی Gemini 2.5 Flash و Gemini 3.5 Flash بر روی نمونه‌های گفتار کودکان مقایسه شده است. نتایج این ارزیابی در جدول ۲-۳ گزارش گردیده است.

جدول ۲-۳: مقایسه عملکرد سامانه‌های خوراک صوتی مستقیم چندوجهی بر روی گفتار کودکان

پیکربندی مدل چندوجهی	نوع استقرار	نرخ خطای کلمه (WER)	نرخ خطای نویسه (CER)
Qwen2-Audio-7B-Instruct	محلی (متن‌باز)	۱۴۷/۹۲٪	۱۲۸/۷۲٪
Gemini 2.5 Flash Direct	ابری (API)	۳۴/۵۵٪	۲۱/۵۴٪
Gemini 3.5 Flash Direct	ابری (API)	۲۷/۵۲٪	۱۲/۹۰٪

۱-۳-۳ تحلیل رفتار و علل شکست مدل محلی Qwen2-Audio

همانطور که در جدول ۲-۳ مشاهده می‌شود، مدل محلی Qwen2-Audio عملکرد بسیار ضعیفی را ثبت کرده است. تحلیل دقیق خروجی‌های این مدل نشان‌دهنده عوامل زیر در این شکست موثر است:

- **توهم زبانی و بیش‌تولید شدید:** این مدل در مواجهه با گفتار کودکان فارسی‌زبان که دارای نوسانات فرکانسی زیاد و تلفظ‌های نامفهوم است، به شدت دچار ابهام شده و عبارات متنی بسیار طولانی و

^۳Weakly Supervised Data

کاملاً بی‌ارتباط با فایل صوتی (گاه به زبان انگلیسی یا عربی) تولید می‌کند.

- **عدم پشتیبانی مناسب از زبان فارسی در لایه چندوجهی صوتی:** اگرچه مدل متنی Qwen زبان فارسی را به خوبی پشتیبانی می‌کند، اما لایه رمزگذار صوتی آن بر روی حجم بسیار محدودی از داده‌های گفتاری فارسی آموزش دیده است که این نقیصه در صدای کودکان به عنوان یک دامنه خارج از توزیع تشدید می‌شود.

۲-۳-۳ تحلیل کارایی متمایز مدل‌های چندوجهی گوگل (Gemini)


در نقطه مقابل، خوراک صوتی مستقیم به مدل‌های خانواده جمینی نتایج بسیار برجسته و فراتر از سامانه‌های سنتی به همراه داشت. این بهبود چشمگیر، نشان‌دهنده برتری روش چندوجهی مستقیم نسبت به روش‌های آبشاری است. با حذف لایه واسطه ASR، اطلاعات آکوستیکی غنی سیگنال صوتی (نظیر لحن، مکث‌ها و تکیه‌های صدا) از بین نرفته و مدل زبانی با دسترسی مستقیم به این اطلاعات، رمزگشایی معنایی دقیق‌تری انجام می‌دهد.

نقش کلیدی مهندسی پرامپت چندوجهی

یکی از یافته‌های تجربی بسیار مهم در ارزیابی مدل‌های چندوجهی مستقیم، حساسیت شدید آن‌ها به نحوه طراحی دستورالعمل‌ها (پرامپت) است. ارزیابی‌های اولیه با پرامپت‌های عمومی و ساده (مانند «صدا را پیاده‌سازی کن») با شکست مواجه گردید؛ زیرا مدل تمایل داشت گفتار فارسی را به انگلیسی ترجمه کند، توضیحات اضافی متنی ارایه دهد یا نویزهای پس‌زمینه را توصیف کند.

پس از طی یک فرآیند طولانی مهندسی پرامپت^۴، پرامپت سیستم به شکلی بهینه‌سازی شد که شامل چهار قانون و یک مثال ساختاریافته کودکانه فارسی باشد. این پرامپت با تعریف دقیق نقش مدل به عنوان سیستم تخصصی بازشناسی گفتار کودکان فارسی‌زبان، محدود کردن خروجی به متن مطلق، و ارائه راهبرد مشخص برای زمان مواجهه با سکوت یا نویز برای جلوگیری از توهم آکوستیکی، عملکرد استنباطی مدل را به شدت ارتقا بخشید و به پایداری خروجی کمک شایانی نمود.

^۴ Prompt Engineering



نمودار ۳-۱: مقایسه جامع نرخ خطای کلمه (WER) و نویسه (CER) مدل‌های مختلف بر روی گفتار کودکان


۳-۳-۳ پیکره‌های گفتاری و پیکربندی تنظیم دقیق کارا (PEFT/LoRA)

به منظور انطباق مستقیم ویژگی‌های آکوستیکی مدل‌های خانواده Whisper با گفتار کودکان، رویکرد تنظیم دقیق کارا با استفاده از تطبیق‌دهنده‌های با رتبه پایین (LoRA)^۵ مورد ارزیابی قرار گرفت. فرآیند آموزش و ارزیابی این بخش بر روی پایگاه‌های داده طبیعی و شبیه‌سازی شده انجام پذیرفت که جزئیات توزیع و آماده‌سازی آن‌ها پیش‌تر در بخش ۳-۱-۱ تشریح گردید. در این فاز، ابرپارامترهای بهینه‌سازی مدل به شرح زیر تعریف شدند:

فرآیند بهینه‌سازی ابرپارامترها از طریق جستجوی تصادفی^۶ برای یافتن بهترین ضریب یادگیری (LR)، رتبه لورا (r) و ضریب مقیاس (alpha) پیاده‌سازی گردید.

ارزیابی مدل‌های خام و مدل‌های تنظیم‌دقیق‌شده بر روی مجموعه داده آزمون مستقل و کاملاً دیده‌نشده انجام گرفت. نتایج کمی حاصل از این مقایسه در نمودار ۳-۲ ارائه شده است.

^۵ Low-Rank Adaptation
^۶ Random Search



نمودار ۲-۳: مقایسه تاثیر تنظیم دقیق کارا (LoRA) بر نرخ خطای کلمه (WER) در مجموعه داده آزمون مستقل

ارزیابی دقیق نتایج نمودار ۲-۳ نشان‌دهنده یک رفتار متناقض و در عین حال تفسیرپذیر میان مدل‌های Whisper Base و Whisper Large-v3 پس از اعمال تنظیم دقیق لورا (LoRA) است. در مدل کوچک‌تر (Base)، میزان خطای کلمه با بهبود مطلق ۴/۹۲٪ مواجه گردید، در حالی که در مدل بزرگ‌تر (Large)، کارایی سیستم به شدت افت کرد و نرخ خطای کلمه از ۲۶/۲۳٪ در حالت خام به ۴۵/۹۰٪ پس از تنظیم دقیق افزایش یافت.

این اختلاف فاحش در رفتار مدل‌ها، مستقیماً به رابطه میان ظرفیت یادگیری معماری‌ها (تعداد پارامترها) و حجم مجموعه داده آموزشی بستگی دارد. مدل Whisper Base با حدود ۷۴ میلیون پارامتر، ظرفیت محدودی دارد و به همین دلیل در مواجهه با داده‌های کوچک آموزشی (شامل ۱۱ نمونه واقعی و ۱۰۰ جمله سنتز شده)، بدون تغییر شدید در وزن‌های از پیش آموزش دیده، توانسته است انطباق صوتی اولیه با صدای کودکان را کسب کند. در نقطه مقابل، مدل Whisper Large-v3 با داشتن بیش از ۵/۱ میلیارد پارامتر، ظرفیت یادگیری بسیار بالایی دارد. هنگامی که چنین مدل عظیمی با حجم بسیار محدودی از داده‌های صوتی مواجه می‌شود، به سرعت دچار بیش‌برازش شدید روی ویژگی‌های فرکانسی منحصربه‌فرد گویندگان محدود دوره آموزش می‌گردد. این امر سبب می‌شود تا کارایی مدل در مواجهه با داده‌های آزمون مستقل کاملاً فرسایش یابد.


علاوه بر این، مدل بزرگ خام دارای دانش زبانی و متنی پیش‌فرض بسیار قدرتمندی از زبان فارسی است. وارد کردن سیگنال‌های صوتی مصنوعی ناشی از چسباندن کلمات مجزا (که فاقد جریان طبیعی زبان و نوای گفتار واقعی هستند)، ساختار توجه رمزگشای مدل را با الگوهای غیرطبیعی مواجه کرده و منجر به پدیده فراموشی فاجعه‌بار (Catastrophic Forgetting) در لایه‌های زبانی پیشین مدل شده است.

همچنین، استفاده از نرخ یادگیری ثابت $10^{-4} \times 5$ در فرآیند بهینه‌سازی تصادفی، برای پایدار نگه‌داشتن وزن‌های تطبیق‌دهنده مدل بزرگی مانند Whisper Large بسیار بالا بوده و به ناپایداری لایه‌های لورا در حین همگرا شدن کمک کرده است.

با تکیه بر این یافته‌ها، می‌توان استدلال نمود که روش تنظیم دقیق کارا ذاتاً یک راهکار موثر است؛ اما اثربخشی آن به شدت توسط حجم داده‌های آموزشی محدود می‌شود. در صورتی که دسترسی به یک پیکره صوتی جامع، بزرگ و طبیعی از گفتار کودکان فارسی‌زبان فراهم باشد، مدل Whisper Large-v3 به واسطه ظرفیت بالای خود قادر خواهد بود بردارهای صوتی صدای کودکان را به صورت عمومی‌تر یاد بگیرد و بدون تخریب پایگاه دانش متنی خود، بهبود بسیار بالاتری را نسبت به نسخه خام به ثبت برساند. در شرایط فعلی و با وجود محدودیت شدید در داده‌های کودکان، استفاده از مدل خام بزرگ در کنار سیستم‌های پس‌پردازش معنایی متنی یا بهره‌گیری مستقیم از خوراک صوتی چندوجهی، رویکرد عملیاتی بسیار موفق‌تری به شمار می‌رود.

۴-۳ بحث و مقایسه جامع روش‌ها

برای ارائه یک دیدگاه کلان و مقایسه همه‌جانبه دستاوردهای این پژوهش، تمامی روش‌ها و پیکربندی‌های ارزیابی‌شده در طول پروژه در نمودار ۳-۳ قرار گرفته‌اند. این مقایسه به ما اجازه می‌دهد تا بده‌بستان‌های کلیدی میان دقت، تاخیر پردازشی، مستقل بودن سیستم و هزینه‌های عملیاتی را واکاوی کنیم.



نمودار ۳-۳: نمودار پراکندگی نرخ خطای کلمه (WER) در برابر نرخ خطای نویسه (CER)

تمرکز اصلی روش‌های پیشنهادی در این پژوهش (شامل هر دو رویکرد خط لوله پس‌پردازش متنی تصحیح خطا و تنظیم دقیق کارا) بر مدل پایه Whisper Base معطوف شده است. این انتخاب بر اساس دو یافته تجربی کلیدی توجیه می‌گردد: اولاً، خط لوله‌های پس‌پردازش کلاسیک و مبتنی بر مدل زبانی بزرگ (LLM) بهبود چشمگیری در عملکرد این مدل سبک نشان دادند؛ به طوری که نرخ خطای کلمه (WER) از ۱۰۲/۷۷٪ به ترتیب به ۸۰/۷۶٪ و ۶۸/۸۸٪ کاهش یافت. ثانیاً، فرآیند تنظیم دقیق لورا (LoRA) نیز در ارزیابی آزمون مستقل به بهبود کارایی مدل Whisper Base کمک نمود و نرخ خطا را از ۸۰/۳۳٪ به ۷۵/۴۱٪ رساند. از آنجا که این مدل با ۷۴ میلیون پارامتر بسیار سبک‌تر از نسخه‌های دیگر است، ارتقای عملکرد آن ارزش عملیاتی بالایی جهت استقرار محلی و کم‌هزینه دارد.

در مقابل، مدل بزرگ Whisper Large-v3 با وجود کارایی اولیه مناسب (۵۴/۸۹٪) در حالت خام کل دادگان و ۲۶/۲۳٪ در آزمون مستقل)، به دلیل تعداد پارامترهای بسیار بالا (۵/۱ میلیارد پارامتر) برای بهبود از طریق تنظیم دقیق نیازمند یک پیکره بزرگ، طبیعی و برجسته‌گذاری شده از گفتار کودکان فارسی‌زبان است. فرآیند تنظیم دقیق این مدل بر روی نمونه‌های محدود فعلی سبب بیش‌برازش (Overfitting) و افت جدی دقت به ۴۵/۹۰٪ گردید؛ اما در صورت جمع‌آوری دادگان کافی در آینده، بدون شک ظرفیت بالای مدل بزرگ به نتایج بسیار برجسته‌تری ختم خواهد شد.

در نهایت، پیرامون مدل‌های ابری چندوجهی نظیر Gemini 2.5 و 3.5 که بهترین عملکرد بازشناسی مستقیم را ارائه کردند، باید به این نکته اشاره کرد که این سامانه‌ها اختصاصی و کد بسته (Closed-Source) می‌باشند. این ویژگی باعث می‌شود پژوهشگران به وزن‌های شبکه دسترسی نداشته باشند و عملاً امکان شخصی‌سازی، بهینه‌سازی اختصاصی یا استقرار محلی آن‌ها در کاربردهای حساس فراهم نباشد. از این جهت، تنظیم و بهبود کارایی مدل‌های متن‌باز بومی نظیر Whisper Base از اهمیت راهبردی بالاتری برخوردار است.

۵-۳ نتیجه‌گیری

پژوهش حاضر با هدف تحلیل چالش‌های بنیادین بازشناسی گفتار کودکان فارسی‌زبان و ارائه راهکارهای عملیاتی و مقیاس‌پذیر برای بهبود کارایی سامانه‌های ASR در شرایط کم‌منبع ساختاردهی شد. گفتار کودکان به دلیل تفاوت‌های آناتومیک مجرای صوتی و رفتار شناختی خاص، دچار انحراف شدید از داده‌های آموزشی بزرگسالان است که این امر منجر به افت فاحش عملکرد مدل‌های خام پایه می‌گردد. برای غلبه بر این چالش، رویکردهای مختلفی شامل استنتاج مدل‌های پایه، خط لوله‌های پس‌پردازش متنی، خوراک صوتی مستقیم چندوجهی و تنظیم دقیق کارا (PEFT) مورد ارزیابی قرار گرفت.

یافته‌های کلیدی این پژوهش عبارتند از:

۱. ناتوانی مدل‌های پایه آفلاین سبک: مدل‌های پایه خام نظیر Whisper Base و Vosk به دلیل حجم کم پارامترها و عدم تطابق شدید حوزه آکوستیکی، با نرخ خطای کلمه نزدیک یا بالای ۱۰۰ درصد مواجه هستند. این مدل‌ها به دلیل پدیده‌هایی مانند توهم آکوستیکی و جابجایی واج‌ها، بدون لایه‌های اصلاحی عملاً غیرقابل استفاده می‌باشند.

۲. اثربخشی لایه‌های پس‌پردازش متنی: خط لوله پیشنهادی مبتنی بر پس‌پردازش متنی نشان داد که ترکیب فیلترهای کلاسیک (تطابق قطعی و فازی واژگان) با بازسازی معنایی مدل‌های زبانی بزرگ (Gemini 2.5 Flash) بر روی مدل متوسط Whisper Base، می‌تواند نرخ خطای کلمه و نرخ خطای نویسه را کاهش دهد. این روش ثابت کرد که بدون نیاز به محاسبات سنگین و بازآموزی، می‌توان خطاهای املایی، پدیده هکسره و شکسته‌نویسی کودکان را به طور موثری اصلاح کرد.

۳. سرآمدی روش چندوجهی مستقیم: ارزیابی خوراک صوتی مستقیم صوتی به مدل چندوجهی Gem-ini 3.5 Flash منجر به ثبت بهترین عملکرد کل پروژه شد. این دستاورد، برتری رویکرد یکپارچه استنباط آکوستیک و درک زبانی را به اثبات رساند. در مقابل، مدل محلی چندوجهی Qwen2-Audio به دلیل ضعف در لایه رمزگذار صوتی فارسی، با شکست مواجه شد.

۴. پیچیدگی‌های تنظیم دقیق روی داده‌های کم‌منبع: ارزیابی فرآیند تنظیم دقیق لورا (LoRA) نشان داد که اگرچه مدل کوچک Whisper Base بهبود نسبی در خطای کلمه داشت، اما مدل بزرگ Whisper Large-v3 به دلیل حجم بالای پارامترها و حجم ناچیز داده‌های آموزش، دچار بیش‌برازش شدید و فراموشی فاجعه‌بار دانش زبانی پیشین خود گردید که منجر به افت کارایی در مجموعه داده آزمون مستقل شد.

۳-۶ چشم‌اندازهای توسعه

نتایج و محدودیت‌های مشاهده‌شده در طول این پژوهش، مسیرهای تحقیقاتی ارزشمندی را برای پژوهش‌های آتی در این حوزه ترسیم می‌کند:

- طراحی سامانه ارزیابی امتیاز اطمینان با رویکرد انسان در حلقه (HITL) و یادگیری تقویت‌شده: پیشنهاد می‌شود یک لایه امتیازدهی اطمینان ترکیبی پیاده‌سازی شود که با تلفیق معیارهای آکوستیکی (مانند آنتروپی رمزگشای مدل ASR) و معیارهای زبانی (ارزیابی خودکار همگرایی معنایی توسط

مدل زبانی بزرگ)، جملات صوتی با خطای بالا و اطمینان پایین را شناسایی کند. این جملات جهت تصحیح به ناظر انسانی ارجاع داده می‌شوند. در ادامه، با استفاده از الگوهای تصحیح‌شده انسانی، قواعد تصحیح واژگانی جدید به صورت خودکار استخراج گردیده و به واژه‌نامه مرجع (Lexicon) افزوده می‌شود. علاوه بر این، می‌توان از داده‌های ترجیحی ناظران انسانی برای تنظیم دقیق مدل زبانی پس‌پردازشگر با استفاده از الگوریتم‌های یادگیری تقویت‌شده از بازخورد انسانی (نظیر RLHF/DPO) بهره برد تا سیستم به مرور زمان رفتاری پویاتر و منطبق با خطاهای واقعی آوایی کودکان پیدا کند.

- **توسعه پیکره صوتی بومی و استاندارد کودکان فارسی‌زبان:** بزرگ‌ترین مانع در آموزش مدل‌های مقاوم آکوستیک بومی، فقدان داده‌های طبیعی و متوالی گفتار کودکان است. تلاش جهت جمع‌آوری، برچسب‌گذاری و استانداردسازی مجموعه داده‌های جامع صوتی از کودکان در سنین مختلف و با لهجه‌های متنوع، اولویت اول تحقیقات آتی است.
- **بومی‌سازی و تنظیم دقیق مدل‌های چندوجهی صوتی متن‌باز محلی:** با توجه به اهمیت حریم خصوصی گفتار کودکان و محدودیت‌های سرویس‌های ابری تجاری، تنظیم دقیق کارا بر روی مدل‌های چندوجهی متن‌باز صوتی نظیر Qwen2-Audio یا LLaMA-Omni با استفاده از پیکره‌های صوتی فارسی متمرکز، می‌تواند به توسعه سیستم‌های محلی امن و درنگ‌زمان کمک کند.
- **ادغام تحلیل‌های واج‌شناختی و آوایی در لایه پس‌پردازش زبانی:** ترکیب بردارهای تعبیه‌شده آوایی (مانند چارچوب‌های هم‌تراز با PERCORE [۹]) در پرامپت مهندسی‌شده مدل زبانی، به مدل اجازه می‌دهد تا علاوه بر روابط معنایی، شباهت‌های آوایی کلمات مخدوش خام را نیز در تصحیح خطا دخالت دهد و از وقوع خطاهای معنایی ناخواسته جلوگیری کند.
- **بهینه‌سازی خط لوله برای جریان‌های صوتی بلادرنگ (Streaming ASR):** تعامل طبیعی کودکان با دستیارهای صوتی و ربات‌های آموزشی نیازمند پردازش جریانی و کلمه به کلمه است. طراحی الگوریتم‌های ناهمگام و انطباق لایه‌های پس‌پردازش با گفتار پیوسته و درنگ‌زمان، چالش فنی جذابی برای توسعه ابزارهای آموزشی و درمانی هوشمند محسوب می‌شود.

Bibliography

- [1] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever. Robust speech recognition via large-scale weak supervision, 2022.
- [2] N. Sedghiyeh, S. Sadeghi, R. Khodadadi, F. Kashani, O. Aghdaei, S. Rahimi, and M. S. Safari. Psrb: A comprehensive benchmark for evaluating persian automatic speech recognition systems, 2025.
- [3] A. Abaskohi, F. Mortazavi, and H. Moradi. Automatic speech recognition for speech assessment of persian preschool children, 2022.
- [4] S. Lee, A. Potamianos, and S. S. Narayanan. Analysis of children’s speech: duration, pitch and formants. In G. Kokkinakis, N. Fakotakis, and E. Dermatas, editors, *Fifth European Conference on Speech Communication and Technology, EUROSPEECH 1997, Rhodes, Greece, September 22-25, 1997*, pages 473–476. ISCA, 1997.
- [5] S. Lee, A. Potamianos, and S. Narayanan. Acoustics of children’s speech: Developmental changes of temporal and spectral parameters. *The Journal of the Acoustical Society of America*, 105(3):1455–1468, 03 1999.
- [6] A. Robatian, M. Hajipour, M. R. Peyghan, F. Rajabi, S. Amini, S. Ghaemmaghami, and I. Gholampour. Gec-rag: Improving generative error correction via retrieval-augmented generation for automatic speech recognition systems, 2025.
- [7] H. H. Mohammadi, A. Talebpour, A. M. Aznaveh, and S. Yazdani. Mehr: A persian coreference resolution corpus. *Journal of AI and Data Mining*, 11(3):413–424, 2023.
- [8] Z. Rahmani and H. Sameti. Incorporating error level noise embedding for improving llm-assisted robustness in persian speech recognition, 2025.

- [9] S. M. S. Dashti, A. K. Bardsiri, and M. J. Shahbazzadeh. Percore: A deep learning-based framework for persian spelling correction with phonetic analysis. *International Journal of Computational Intelligence Systems*, 17:114, 2024.
- [10] R. Ma, M. Qian, M. Gales, and K. Knill. Asr error correction using large language models, 2024.
- [11] V. I. Levenshtein. Binary codes capable of correcting deletions, insertions, and reversals. *Soviet physics doklady*, 10(8):707–710, 1966.
- [12] M. Adibian and S. Momtazi. Converting persian informal text to formal using transformer-based neural networks. *Journal of Language and Linguistics*, 18(35):1–23, 2022.
- [13] OpenAI. Speech to text - openai api documentation, 2024.
- [14] Google. Gemini api documentation - models and pricing, 2024.
- [15] M. Khanzadi, H. Veisi, R. Alinaghizade, and Z. Soleymani. Persian phoneme and syllable recognition using recurrent neural networks for phonological awareness assessment. *Journal of AI and Data Mining*, 10(1):117–126, 2022.



Sharif University of Technology
Department of Mathematical Sciences

B.Sc. Thesis

Enhancing Automatic Speech Recognition for Child Speech in Low-Resource Languages

By:

Amin Hashemi

Supervisor:

Prof. Alireza Zarei

Jun 2026